Sistema de Inteligência Prescritiva para Suporte à Tomada de Decisão Estratégica na Indústria Farmacêutica

Guilherme Gomes Arantes Teles Marcos Arambasic Rebelo da Silva
Matheus Alonso Varjão
Ivan Carlos Alcantra de Oliveira

Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

<Guilherme.telles@mackenzista.com.br>

<marcosarambasic.silva@mackenzista.com.br>

<matheus.varjao@mackenzista.com.br>

<ivan.oliveira@mackenzie.br>

2026

Resumo: *A crescente complexidade da gestão comercial na indústria farmacêutica brasileira impõe desafios analíticos que os sistemas tradicionais de Business Intelligence (BI) não conseguem suprir de forma prescritiva. Este trabalho propõe uma arquitetura multiagente baseada em Large Language Models (LLMs) para o desenvolvimento de um Sistema de Inteligência Prescritiva capaz de cruzar dados de performance da força de vendas, indicadores de mercado e notícias externas, convertendo-os em recomendações táticas acionáveis para gestores e diretores comerciais. Cinco agentes especializados: i) Classificador de Impacto, ii) Validador, iii) Comparador de Vendas, iv) Identificador de Riscos e v) Oportunidades e Gerador de Recomendações, que operam sob coordenação de um Agente Orquestrador, seguindo o padrão orquestrador-executor. Para a etapa de rotulação do corpus de notícias foram classificadas 1.415 notícias no período de 2023 à 2026, avaliados por três níveis de impacto (alto, médio e baixo). A estatística da Kappa de Fleiss resultou em K = 0,1858, indicando concordância fraca com 27,42% de concordância perfeita entre os três avaliadores. Diante disso, foi incorporado um agente de desempate baseado na Application Programming Interface (API) da OpenAI para resolução de casos de discordância total. Os resultados parciais indicam que a arquitetura proposta é tecnicamente viável, com os pipelines Extract, Transform and Load (ETL) estruturados com volume acima de um milhão de registros compreendidos entre 2023 e 2026 e os agentes 1 e 2 operacionais em ambiente de testes. Conclui-se que a integração de LLMs com dados multimodais do setor farmacêutico tem potencial significativo com a geração de oportunidades e recomendações para otimizar decisões comerciais e antecipar riscos regulatórios e competitivos.*

Palavras-chave: *Inteligência prescritiva, LLMs, Arquitetura multiagente, Indústria farmacêutica, Tomada de decisão estratégica, Kappa Fleiss.*

Abstract:*. The growing complexity of commercial management in the Brazilian pharmaceutical industry poses analytical challenges that traditional Business Intelligence (BI) systems are unable to address in a prescriptive manner. This study proposes a multi-agent architecture based on Large Language Models (LLMs) for the development of a Prescriptive Intelligence System capable of cross-referencing sales force performance data, market indicators, and external news, converting them into actionable tactical recommendations for managers and commercial directors. Five specialized agents are defined: (i) Impact Classifier, (ii) Validator, (iii) Sales Comparator, (iv) Risk and Opportunity Identifier, and (v) Recommendation Generator, operating under the coordination of an Orchestrator Agent following the orchestrator–executor pattern.*

For the news corpus labeling stage, 1,415 news items from the period 2023 to 2026 were classified and evaluated across three impact levels (high, medium, and low). Fleiss' Kappa statistic resulted in K = 0.1858, indicating weak agreement, with 27.42% perfect agreement among the three evaluators. In response, a tie-breaking agent based on the OpenAI Application Programming Interface (API) was incorporated to resolve cases of total disagreement. Partial results indicate that the proposed architecture is technically feasible, with Extract, Transform, and Load (ETL) pipelines structured to handle volumes exceeding one million records covering the period from 2023 to 2026, and agents 1 and 2 operating in a test environment. It is concluded that the integration of LLMs with multimodal data from the pharmaceutical sector has significant potential for generating opportunities and recommendations to optimize commercial decision-making and anticipate regulatory and competitive risks.

Palavras-chave: *Prescriptive Intelligence, LLMs, multi-agent architecture, pharmaceutical industry, strategic decision-making, Fleiss' Kappa*

1. Introdução

No Brasil, segundo a ANVISA (2025), o mercado farmacêutico movimentou aproximadamente R$ 190 bilhões em 2025, posicionando o país entre os dez maiores mercados do setor no mundo. Nesse contexto, a força de vendas dos laboratórios farmacêuticos opera sob pressão crescente para atingir metas comerciais enquanto enfrenta mudanças regulatórias frequentes, flutuações de demanda e concorrência intensa, especialmente após a expansão do mercado de medicamentos genéricos e biossimilares.

Em decorrência desse cenário, a gestão comercial farmacêutica produz volumes expressivos de dados heterogêneos: registros de visitação médica, histórico de vendas por produto e território, relatórios de *market share*, alertas regulatórios da ANVISA (2025) e notícias do setor. A capacidade de integrar e interpretar esse conjunto multimodal de informações de forma oportuna constitui uma vantagem competitiva decisiva (WISSUCHEK; ZSCHECH, 2025). Contudo, os sistemas tradicionais de *Business Intelligence (BI*) operam predominantemente de forma descritiva ou, no melhor dos casos, preditiva, sendo incapazes de converter dados em recomendações táticas prescritivas de forma automatizada (GARTNER, 2023).

Nesse contexto, os avanços recentes em *Large Language Models (LLMs*), como o *GPT-4* (BROWN et al., 2020), abrem uma nova fronteira para a automação do raciocínio analítico em ambientes de negócios complexos. A técnica de *chain-of-thought prompting* (WEI et al., 2022) demonstrou que *LLMs* são capazes de decompor problemas em etapas de raciocínio encadeado, produzindo análises explicáveis e contextualizadas. Quando organizados em arquiteturas multiagente sob um padrão orquestrador-executor (GUO et al., 2024), esses modelos podem atuar de forma colaborativa para processar diferentes dimensões de um problema e gerar *outputs* integrados.

No contexto da indústria farmacêutica, a adoção de sistemas prescritivos ainda é embrionária, com a maior parte das organizações operando no nível descritivo ou preditivo (GARTNER, 2023). A lacuna existente entre a geração de dados e a conversão desses dados em ações táticas constitui o problema central que este trabalho se propõe a endereçar.

Diante disso, este trabalho propõe como objetivo geral o desenvolvimento de um sistema de inteligência prescritiva baseado em arquitetura multiagente com *LLMs*, capaz de cruzar performance da força de vendas, indicadores de mercado e notícias externas, convertendo-os em recomendações táticas para otimizar o faturamento de laboratórios farmacêuticos.

Para atingir o objetivo geral proposto, os objetivos específicos são: geral um sistema prescritivo para auxilio de faturamento de medicamentos para a força de vendas da indústria farmacêutica.

Este trabalho se qualifica como uma pesquisa de caráter quantitativo e exploratório, pois baseia-se na coleta e análise de dados numéricos para desenvolver um sistema prescritivo gerado no contexto proposto, bem como investigar sua aplicabilidade na gestão comercial de laboratórios farmacêuticos.

Para viabilizar a execução do estudo com maior precisão analítica e controle metodológico, optou-se por uma delimitação explícita do escopo, restringindo o domínio de investigação a um nicho terapêutico específico da indústria farmacêutica: o mercado de medicamentos para diabetes. Com esse recorte, tanto a coleta de notícias quanto a consolidação dos indicadores de desempenho foram direcionadas exclusivamente a eventos, produtos e

dinâmicas competitivas relacionadas a essa categoria, assegurando coerência temática entre as fontes externas e os dados internos analisados. Essa escolha reduz o ruído decorrente de múltiplas áreas terapêuticas simultâneas, facilita a validação dos resultados e permite avaliar com maior consistência a capacidade do sistema proposto em transformar sinais do mercado e desempenho comercial em recomendações táticas dentro de um contexto bem definido.

2. Referencial Teórico

De acordo com Creswell e Creswell (2021), o referencial teórico é o alicerce lógico e a lente explicativa que orienta a investigação, estabelecendo as conexões entre o problema de pesquisa e o conhecimento já validado. Ele funciona como uma estrutura para organizar as variáveis no método quantitativo ou como uma perspectiva interpretativa no qualitativo. Em suma, seu significado reside em fornecer o mapa conceitual que justifica, direciona e dá significado aos achados do estudo.

2.1. Inteligência Prescritiva

A inteligência analítica em organizações pode ser compreendida como uma progressão de quatro níveis: descritiva (relata o que aconteceu), diagnóstica (explica por que aconteceu), preditiva (estima o que pode acontecer) e prescritiva (orienta o que fazer a seguir). Nesse continuum, a analítica prescritiva é considerada o estágio mais avançado por agregar uma camada explícita de recomendação e decisão sobre os resultados analíticos, isto é, além de antecipar cenários, busca determinar cursos de ação para atingir objetivos e evitar desfechos indesejáveis. (WISSUCHEK; ZSCHECH, 2025).

Sob a perspectiva de Sistemas de Analítica Prescritiva (PAS), a dimensão prescritiva se materializa em artefatos sociotécnicos que ampliam a tomada de decisão organizacional, incorporando componentes de inteligência artificial e *machine learning* e mecanismos de recomendação com diferentes graus de autonomia e interação humano sistema. Nessa visão, a prescrição não é apenas "sugerir" ações, mas estruturar sinergias e delegação entre decisores e sistemas, podendo assumir arquiteturas que variam de conselheiros, sendo de apoio ao executivo ou a governança, onde detém maior capacidade de execução e adaptação. Assim, a analítica prescritiva se distingue por transformar previsões e evidências em recomendações acionáveis, potencialmente priorizadas e condicionadas por restrições e trade-offs do contexto, aproximando "*insight*" de "intervenção" na prática gerencial. (IBM, 2022)

2.2. Large Language Models - LLMs

Modelos de Linguagem de Grande Escala (*Large Language Models – LLMs*) são redes neurais baseadas em arquiteturas *transformer* treinadas em grandes volumes de texto, capazes de executar tarefas de compreensão e geração de linguagem natural com elevada coerência e adaptação ao contexto. A literatura demonstra que o aumento de escala e o uso de exemplos no próprio *prompt* viabilizam desempenho robusto em cenários *zero-shot* e *few-shot*, reduzindo a dependência de retreinamento para cada tarefa e viabilizando aplicações mais flexíveis em ambientes reais (BROWN et al., 2020)

Nesse cenário, o GPT-4 (*Generative Pre-trained Transformer* 4), desenvolvido pela OpenAI, representa um modelo multimodal de grande porte que recebe entradas em texto e produz saídas textuais, com ganhos relevantes em avaliações acadêmicas e profissionais, além de melhorias de alinhamento e maior aderência a instruções após processos de *post-training*

(OPENAI, 2023). No contexto deste trabalho, LLMs são importantes não apenas como "modelos de texto", mas como um mecanismo geral de raciocínio e síntese capaz de: (i) consolidar evidências provenientes de múltiplas fontes (bases e APIs), (ii) transformar sinais em linguagem decisória, e (iii) produzir recomendações estruturadas para o negócio, mantendo consistência semântica entre justificativas, ações e consequências previstas (OPENAI, 2023; BROWN et al., 2020).

Para ampliar o desempenho dos LLMs em tarefas complexas, técnicas de *prompting* com decomposição do problema em passos intermediários tornaram-se relevantes. Em particular, o *chain-of-thought prompting* explora a indução de etapas intermediárias para melhorar resultados em tarefas que exigem raciocínio aritmético, simbólico ou de senso comum, apresentando ganhos empíricos significativos em *benchmarks* de raciocínio (WEI et al., 2022).

A relevância dos LLMs neste trabalho se torna ainda mais evidente quando se considera a arquitetura multiagente. Sistemas multiagentes baseados em LLM têm avançado rapidamente ao especializar agentes com papéis distintos e ao coordenar suas interações para resolver tarefas complexas com maior robustez do que abordagens monolíticas (GUO et al., 2024). Essa decomposição é particularmente adequada quando o problema envolve múltiplas competências, pois permite modularidade, reuso e avaliação isolada de componentes, além de favorecer mecanismos de verificação cruzada entre agentes (GUO et al., 2024). De forma complementar, *frameworks* voltados a conversação e coordenação entre agentes, como *AutoGen*, evidenciam que a composição de múltiplos agentes conversáveis, incluindo agentes com ferramentas e humanos no *loop*, pode ampliar a capacidade do sistema em tarefas de planejamento, validação e tomada de decisão, oferecendo uma infraestrutura prática para orquestrar interações e responsabilidades (WU et al., 2023).

2.3. Arquitetura Multiagente

Um sistema multiagente baseado em LLMs pode ser entendido como um arranjo de múltiplos agentes especializados que cooperam por meio de comunicação e coordenação para resolver tarefas complexas, superando abordagens de agente único principalmente quando há necessidade de planejamento, divisão de trabalho e integração de evidências heterogêneas (GUO et al., 2024). Estudos recentes sistematizam esse campo ao destacar que a decomposição em agentes com perfis e competências distintas melhora robustez, modularidade e capacidade de lidar com fluxos multi-etapas, além de permitir avaliação e evolução incremental de cada componente (GUO et al., 2024; LI et al., 2024).

No contexto de implementação, frameworks de orquestração tornam viável instanciar cada agente como um LLM com prompt, ferramentas e estado próprios. O AutoGen formaliza a construção de aplicações via conversas multiagente, permitindo definir padrões de interação e combinar LLMs, ferramentas e participação humana quando necessário (WU et al., 2024).

Para este trabalho, o paradigma multiagente é central porque permite organizar o pipeline como um padrão orquestrador–executor: um agente "orquestrador" decompõe o objetivo, delega subtarefas, e integra os retornos dos "executores" antes da recomendação final. Esse tipo de coordenação é explicitamente suportado por frameworks contemporâneos de conversação multiagente e por arquiteturas hierárquicas descritas na literatura recente de LLM multiagentes (WU et al., 2024; GUO et al., 2024)

2.3.1 Padrão Orquestrador-Executor

O padrão orquestrador–executor ou *plan-then-execute* organiza agentes em dois níveis: um orquestrador que realiza planejamento, decomposição e sequenciamento do trabalho e um conjunto de executores responsáveis por realizar subtarefas específicas e retornar resultados intermediários ao controlador central. Esse arranjo é particularmente indicado quando um único agente, com muitos instrumentos e fontes, se torna difícil de controlar com confiabilidade, pois a coordenação central permite distribuição de trabalho, compartilhamento controlado de contexto e agregação de resultados. Além disso, a separação explícita entre "planejar" e "executar" tende a aumentar previsibilidade e governança do fluxo, pois o plano funciona como um artefato de controle do comportamento do sistema, reduzindo desvios durante a execução e favorecendo auditoria e depuração. (DEL ROSARIO, 2025)

Do ponto de vista de manutenção, esse padrão favorece modularidade: agentes executores podem ser ajustados, substituídos ou escalados (inclusive em paralelo) sem reestruturar o pipeline, mantendo o orquestrador como ponto de integração e monitoramento. Evidências recentes em sistemas multiagentes de referência mostram o orquestrador atuando justamente como componente que cria o plano, delega tarefas, acompanha progresso e replaneja quando necessário, enquanto os executores concentram capacidades especializadas (por exemplo, navegação web, manipulação de arquivos e execução de código), reforçando extensibilidade e isolamento de responsabilidades. (FOURNEY, 2024)

2.4. Concordância Inter-Anotadores e Kappa de Fleiss

Em tarefas de anotação manual de corpora textuais, a mensuração da concordância entre avaliadores é um requisito metodológico para assegurar que os rótulos atribuídos sejam confiáveis, reproduzíveis e adequados ao uso computacional, sobretudo quando a classificação envolve julgamento semântico e ambiguidade interpretativa. Nesses cenários, a estatística Kappa de Fleiss é indicada quando três ou mais anotadores categorizam itens em classes nominais, pois quantifica o quanto a concordância observada excede a concordância esperada ao acaso, evitando interpretações infladas quando há categorias dominantes no conjunto rotulado. (FLEISS, 1971)

Operacionalmente, o método calcula a concordância média por item a partir da distribuição de votos dos anotadores por categoria, estima a concordância esperada com base nas proporções marginais das classes e, então, normaliza a diferença por meio de $\kappa=(\bar{P}-P_e)/(1-P_e)$, em que $\kappa=1$ indica concordância perfeita e $\kappa\approx0$ indica concordância semelhante ao acaso. Para interpretação qualitativa, é comum empregar as faixas de Landis e Koch, que classificam valores de κ de "fraco" a "quase perfeito" (por exemplo, acima de 0,80 como quase perfeito), servindo como referência para relatar a robustez do *corpus* e justificar a validade do processo de anotação. (LANDIS; KOCH, 1977).

No contexto deste trabalho, em que notícias são rotuladas quanto ao impacto que determinadas notícias têm em relação as vendas de medicamentos para diabetes, o Kappa de Fleiss funciona como controle de qualidade do dado que alimenta o pipeline: se a concordância for baixa, isso sugere revisar diretrizes, classes e exemplos de decisão ou adotar mecanismos de desempate, pois rótulos inconsistentes tendem a degradar treinamento, avaliação e estabilidade das etapas subsequentes. Essa análise conecta diretamente a Seção 2.3 e Seção 2.5, uma vez que o nível de confiabilidade medido no corpus orienta decisões de arquitetura no sistema

multiagente para garantir que recomendações finais sejam coerentes, rastreáveis e metodologicamente defensáveis.

2.5. Business Intelligence Farmacêutico

O *Business Intelligence* (BI) é essencial na gestão comercial farmacêutica para consolidar e monitorar indicadores como vendas por produto e território, performance por representante e evolução de *market share*.

Nos últimos anos, o BI tem sido usado para dar visibilidade operacional à rotina da força de vendas e apoiar decisões de cobertura, priorização de contas e metas. Na prática, ele se apoia em CRM farmacêutico, sistemas de força de vendas (SFV) e bases de dados de mercado para gerar relatórios e dashboards de desempenho.

A principal importância dessas ferramentas é transformar grandes volumes de dados operacionais em informações gerenciais padronizadas e comparáveis ao longo do tempo. Entretanto, esse BI tradicional costuma lidar melhor com dados estruturados e métricas já definidas, limitando-se com frequência a análises descritivas e, em alguns casos, preditivas.

Quando entram fontes não estruturadas (notícias, comunicados e alertas regulatórios), a integração se torna mais complexa e exige interpretação semântica. Essa lacuna reduz a capacidade de converter sinais externos em ações táticas no ritmo necessário para decisões comerciais.

Para contornar isso, o projeto utiliza dados sintéticos baseados em estruturas típicas do setor (CRM,SFV e *market data*), preservando a lógica operacional sem expor dados sensíveis.

A contribuição central é acoplar técnicas de processamento de linguagem natural e LLMs para interpretar conteúdo textual e conectá-lo aos indicadores comerciais. Com isso, o BI evolui de “monitorar o passado” para apoiar recomendações acionáveis, integrando desempenho interno e sinais do ambiente externo. (WISSUCHEK; ZSCHECH, 2025).

2.6 Trabalhos correlatos

O primeiro trabalho correlato é a revisão sistemática de Wissuchek e Zschech (2025) sobre Sistemas de Analítica Prescritiva (PAS), que organiza como esses sistemas transformam dados e previsões em recomendações acionáveis, discutindo componentes típicos (integração de dados, mecanismos de decisão, governança) e diferentes níveis de autonomia (de suporte consultivo até execução mais automatizada). A relação com este projeto é direta: o objetivo aqui não é apenas descrever ou prever desempenho comercial, mas prescrever ações táticas para gestores com justificativas e rastreabilidade. Do estudo, será aproveitada a noção de “camada prescritiva” como artefato sociotécnico (dados → decisão → ação), além da ênfase em governança e confiabilidade das recomendações, que orienta o desenho do agente sintetizador (Agente 5) e os critérios para transformar evidências em ações priorizadas (WISSUCHEK; ZSCHECH, 2025).

O segundo trabalho correlato é o *survey* de Guo et al. (2024) sobre sistemas multiagentes baseados em LLMs, que sistematiza arquiteturas, padrões de coordenação, desafios e boas práticas para decompor problemas complexos em agentes especializados com comunicação e coordenação. Esse referencial fundamenta a escolha da arquitetura do presente trabalho, pois o problema envolve múltiplas competências, o que favorece um arranjo modular e verificável. A partir desse trabalho, o projeto incorpora o princípio de especialização por agentes com responsabilidades bem definidas, a coordenação sob um padrão orquestrador–executor para

planejamento, delegação e integração, e a ideia de checagem cruzada entre agentes para reduzir inconsistências antes da recomendação final, elevando robustez e auditabilidade do pipeline (GUO et al., 2024).

O terceiro correlato é o DataLab de Weng et al. (2024), que propõe uma plataforma de *Business Intelligence* (BI) com suporte de LLMs, visando automatizar etapas típicas do ciclo de BI e aproximar dados de decisões em um fluxo mais integrado. A conexão com este projeto está na convergência entre BI e "*agentic workflows*": assim como no DataLab, o objetivo é combinar dados estruturados com sinais externos e produzir saídas consumíveis por decisão. Do trabalho, aproveitamos a ideia de BI orientado por LLM como camada de interpretação e síntese sobre múltiplas fontes, além do enfoque em integração ponta a ponta e na entrega de resultados em formatos. Aqui, essa lógica é adaptada ao recorte do mercado de diabetes e ao pipeline multiagente que culmina em recomendações táticas rastreáveis (WENG et al., 2024).

3. Metodologia

A metodologia deste trabalho detém caráter quantitativo e exploratório, baseando-se na coleta e análise de dados numéricos para gerar um sistema prescritivo. estruturar *pipelines* ETL para coleta de dados de notícias das API The Guardian, GNews e dados farmacêuticos sintéticos; desenvolver e orquestrar cinco agentes especializados com responsabilidades complementares; desenvolvimento de algoritmo *mBert* para classificação de notícias e algoritmo *XGBoost* para cruzamento de notícias com dados de desempenho de vendas; implementar a técnica de *chain-of-thought* nos agentes de identificação de riscos e oportunidades, e geração de recomendações; conduzir processo de anotação manual do *corpus* com mensuração de concordância inter-anotadores via estatística Kappa de Fleiss (FLEISS, 1971); incorporar agente de desempate baseado em LLM para resolução de discordâncias totais; validar o sistema com dados históricos sintéticos da indústria farmacêutica; e desenvolver um painel de *insights* prescritivos voltado ao uso de gestores e representantes pertencentes a força de vendas dos laboratórios. (GUO et al., 2024)

A abordagem metodológica de desenvolvimento da solução compreende cinco etapas sequenciais: (1) ingestão e tratamento de dados por *pipelines* ETL; (2) anotação manual do *corpus* de notícias com mensuração de concordância inter-anotadores; (3) desenvolvimento e orquestração dos agentes especializados; (4) integração e validação do sistema completo com dados históricos sintéticos; e (5) desenvolvimento do painel de *insights*. Cada etapa é detalhada nas subseções a seguir.

3.1. Fontes de Dados e Pipelines ETL

A arquitetura do sistema integra três categorias de fontes de dados, processadas por *pipelines* ETL dedicados antes de serem disponibilizadas aos agentes de IA.

O *pipeline* ETL de notícias realiza a ingestão de conteúdo jornalístico por meio da *API The Guardian* e *GNews*, que fornece cobertura internacional e nacional sobre temas de saúde, regulação farmacêutica, aprovações da Anvisa, além de movimentações do mercado de medicamentos relacionadas ao mercado de diabetes. O processo inclui extração, limpeza, de duplicação e estruturação das notícias em planilha categorizada por data, fonte, relevância temática e produto referenciado. Ao todo, foram coletados e processados 1.415 artigos filtrados por relevância ao setor farmacêutico compreendidas entre 2023 e 2026.

O *pipeline* ETL de dados farmacêuticos realiza a carga incremental de registros sintéticos de vendas representando a estrutura real de dados de laboratórios parceiros, normalizando campos de volume, valor faturado, meta, desvio e identificadores de produto, representante e território. Os dados são exportados em formato .csv padronizado para consumo pelos agentes analíticos.

Adicionalmente, indicadores de mercado, incluindo dados de *market share* nacionais, estaduais e municipais são obtidos por geração de dados sintéticos com base nos dados da indústria farmacêutica e integrados ao *pipeline* de dados farmacêuticos como atributos complementares.

3.2. Anotação Manual do Corpus e Kappa de Fleiss

Para a etapa de rotulação supervisionada do *corpus*, cada integrante do grupo classificou 1.415 notícias (2023–2026) de forma independente em três níveis de impacto no desempenho comercial farmacêutico (alto, médio e baixo). A independência entre avaliadores é uma condição metodológica importante, pois evita que a rotulagem seja influenciada por discussões prévias e permite que a concordância observada reflita, de fato, a clareza das diretrizes e a interpretabilidade do fenômeno analisado, em linha com recomendações clássicas para estudos de anotação em linguística computacional. (ARTSTEIN; POESIO, 2008).

Com o objetivo de quantificar a confiabilidade desses rótulos e identificar divergências sistemáticas entre anotadores, aplicou-se o Kappa de Fleiss, apropriado para cenários com três ou mais avaliadores e categorias nominais. (FLEISS, 1971). Diferentemente da taxa de concordância bruta (percentual simples de coincidência), o Kappa estima o quanto a concordância obtida excede a concordância esperada ao acaso, controlando o efeito de categorias dominantes (por exemplo, quando “médio” é muito mais frequente do que “alto” e “baixo”). (FLEISS, 1971; ARTSTEIN; POESIO, 2008). Assim, o coeficiente fornece uma medida mais robusta da consistência do processo de anotação: valores próximos de 1 indicam alta reprodutibilidade, valores próximos de 0 sugerem concordância equivalente ao acaso e valores negativos podem sinalizar inconsistência grave ou diretrizes inadequadas. (FLEISS, 1971).

No contexto deste estudo, o Kappa de Fleiss cumpre um papel operacional: ele permite avaliar se a tarefa de classificar “impacto comercial” em notícias apresenta subjetividade elevada e, portanto, se o corpus está adequado para treinar e avaliar módulos posteriores (por exemplo, o classificador de notícias e os agentes de validação/síntese). Para interpretação dos resultados, adotam-se faixas qualitativas amplamente citadas na literatura (de concordância fraca a quase perfeita), as quais auxiliam a justificar a confiabilidade do corpus e orientar ajustes nas diretrizes, nas classes ou na necessidade de mecanismos de desempate para itens ambíguos. (LANDIS; KOCH, 1977).

3.3. Agente Orquestrador

O Agente Orquestrador constitui o núcleo de coordenação da arquitetura, sendo responsável pelo planejamento e sequenciamento das tarefas entre os agentes especializados (GUO et al., 2024). Implementado com o *framework LangChain* sobre Python, o orquestrador recebe os dados processados pelos *pipelines* ETL, determina a ordem de acionamento dos

agentes e conforme o tipo de entrada disponível e consolida os *outputs* para geração do painel final.

O orquestrador mantém um registro de estado compartilhado entre os agentes, garantindo que o contexto produzido por agentes anteriores seja acessível aos subsequentes, viabilizando o raciocínio encadeado ao longo do *pipeline* completo.

3.4. Agentes Especializados

De acordo com Silva (2024), um agente especializado é um sistema de IA autônomo focado em um domínio técnico restrito para resolver problemas complexos com alta precisão. Seu trabalho envolve o processamento de dados específicos e a execução de tarefas delimitadas, simulando a competência de um especialista humano. Essa atuação direcionada otimiza fluxos de trabalho, garantindo resultados mais técnicos e seguros que os modelos de propósito geral. A seguir os agentes utilizados para o desenvolvimento e funcionamento do projeto:

3.4.1 Agente 1 – Classificador de Impacto

O Agente 1 processa o *corpus* de notícias e indicadores de mercado utilizando o modelo *mBERT (Multilingual Bidirectional Encoder Representations from Transformers*) (DEVLIN et al., 2019). Para cada notícia ou evento de mercado, o modelo realiza a classificação por meio de sua arquitetura bidirecional, capturando representações contextuais profundas do texto em múltiplos idiomas, o que é particularmente relevante para um *corpus* que abrange fontes de ambas as *APIs*, sendo elas a *The Guardian* e a *GNews*.

O *pipeline* de classificação compreende três etapas: (1) tokenização e geração de *embeddings* contextuais pela camada do *token* especial CLS do *mBERT*; (2) passagem por uma camada densa de classificação *fine-tuned* sobre o corpus anotado pelos avaliadores humanos; (3) atribuição do impacto como Alto, Médio ou Baixo, com *score* de probabilidade *softmax* entre 0 e 1. O modelo foi ajustado (*fine-tuned*) utilizando as anotações consolidadas, com desempates resolvidos pelo Agente de Desempate, como conjunto de treinamento supervisionado, seguindo ade abordagem padrão de classificação de sequências com modelos *BERT* (idem, 2019).

3.4.2 Agente 2 – Validador & Ajuste

O Agente 2 recebe as classificações produzidas pelo Agente 1 e as submete a um processo de validação baseado em dois mecanismos complementares. O primeiro aplica um conjunto de regras de negócio predefinidas, sendo o filtro das classificações que contradizem o histórico documentado de eventos similares e a remoção de notícias classificadas como baixo impacto. O segundo recalibra o score de confiança com base na similaridade semântica entre a notícia atual e eventos históricos de impacto conhecido, utilizando *embeddings* gerados pelo modelo *text-embedding-ada-002* da OpenAI (CHEN et al., 2026).

3.4.3 Agente 3 – Comparador de Vendas

O Agente 3 realiza a análise quantitativa da performance comercial utilizando o algoritmo *Extreme Gradient Boosting (XGBoost*) (CHEN et al., 2026), cruzando os dados de vendas sintéticos com as metas estabelecidas e *benchmarks* de mercado disponíveis. O modelo é treinado sobre séries históricas de vendas por produto, território e representante, aprendendo

padrões de desvio em relação às metas a partir de variáveis como volume faturado, sazonalidade, *market share* relativo e tendência de prescrição.

O *XGBoost* identifica desvios por produto, território e representante, classifica-os por magnitude e tendência, e sinaliza situações de risco de não atingimento de meta com antecedência configurável. Optamos a escolha do *XGBoost* por conta da resistência a *overfitting* via regularização L1/L2 e interpretabilidade por meio de valores de *SHAP*, que permitem identificar quais atributos mais contribuem para cada desvio (CHEN et al., 2026). Os resultados são estruturados em séries temporais que alimentam tanto o Agente 4 quanto o painel de *insights* final.

3.4.4 Agente 4 – Identificador de Riscos e Oportunidades

O Agente 4 correlaciona os outputs dos Agentes 1 e 3 para gerar uma visão integrada de riscos e oportunidades. A correlação é realizada por meio de um espaço vetorial comum construído com *embeddings* semânticos das notícias e representações numéricas dos indicadores de vendas, permitindo identificar padrões de co-ocorrência entre eventos externos e variações comerciais (MICROSOFT, 2026).

Para estruturar o raciocínio analítico sobre os padrões correlacionados, o agente adota a técnica de *chain-of-thought prompting* (WEI et al., 2022; Wang,2023), que induz o modelo a explicitar etapas intermediárias de raciocínio, relacionando, por exemplo, uma tendência de aprovação regulatória identificada pelo Agente 1 com um desvio positivo de vendas detectado pelo Agente 3, antes de emitir uma classificação de risco ou oportunidade. O agente categoriza os achados em três classes: riscos imediatos (horizonte de 0 a 30 dias), riscos de médio prazo (30 a 90 dias) e oportunidades de crescimento.

3.4.5 Agente 5 – Gerador de Recomendações

O Agente 5 sintetiza os *outputs* de todos os agentes anteriores e, utilizando o GPT-4 com *prompts* estruturados e exemplos de recomendações validadas, produz recomendações táticas priorizadas para gestores e diretores comerciais. Cada recomendação inclui: justificativa baseada em dados com rastreabilidade para as fontes originais, nível de urgência (alta, média, baixa), produtos e territórios afetados, ação específica sugerida e impacto esperado no faturamento quando quantificável (WISSUCHEK; ZSCHECH, 2025).

3.5. Agente de Desempate

Em razão do baixo índice de concordância inter-anotadores identificado na etapa de rotulação manual (K = 0,1858), foi incorporado um Agente de Desempate ao *pipeline* de anotação. Desenvolvido por meio da API da OpenAI, o agente recebe os casos de discordância total entre os três avaliadores humanos, no qual os três anotadores tiverem divergência em suas respostas, e produz uma classificação de referência fundamentada no conteúdo integral da notícia, no contexto farmacêutico e nos critérios de impacto definidos pelo projeto.

3.6. Pré-processamento e Integração

Antes de serem submetidos aos agentes, os dados passam por um processo de pré-processamento que inclui: normalização de atributos numéricos, conversão de formatos temporais, de duplicação de notícias redundantes e enriquecimento de registros de vendas com atributos de mercado. A integração entre os *pipelines* ETL e os agentes é gerenciada pelo Agente

Orquestrador, que controla o versionamento dos dados e garante a reprodutibilidade dos experimentos.

3.7. Validação e Avaliação

A validação do sistema será conduzida em duas fases. Na primeira fase, os agentes de classificação (Agentes 1 e 2) serão avaliados com o corpus de referência de 1.415 notícias entre 2023 e 2026 anotadas pelos três avaliadores humanos, com desempates resolvidos pelo Agente de Desempate, utilizando as métricas de precisão, recall e F1-score por classe de impacto. Na segunda fase, as recomendações geradas pelo sistema sobre dados históricos de 12 meses serão avaliadas para conferir a veracidade e acurácia dos insights.

4. Resultados e discussão

Até o momento, as etapas iniciais deste estudo concentraram-se na estruturação dos *pipelines* ETL, na condução do processo de anotação manual do *corpus* de notícias e no desenvolvimento dos Agentes 1 e 2.

4.1. Pipeline ETL e Corpus de Notícias

O *pipeline* de ingestão de notícias foi implementado e testado com sucesso por meio da *API The Guardian*, coletando um *corpus* de 1.415 artigos filtrados por relevância temática ao setor farmacêutico. Os artigos foram distribuídos ao longo do período de 2023 a 2026, abrangendo palavras-chave presentes na Tabela 1.

Tabela 1: Palavras-chaves utilizada na busca das APIs The Guardian e Gnews.

Palavras-chave GNwes (Português)	Palavras-chave The Guardian (Inglês)
Diabetes Mellitus Tipo 2	Diabetes Mellitus Type 2
PBM	PBM
Desastre natural	Natural disaster
Farmácia	Pharmacy
Inibidores de SGLT2	SGLT2 inhibitors
Anvisa	Anvisa
Obesidade	Obesity
GLP-1	GLP-1
Insulina	Insulin
Estoque de medicamento	Medicine stock
Indústria Farmacêutica	Pharmaceutical industry
Hemoglobina Glicada	Glycated Hemoglobin
Gestão Metabólica	Metabolic Management
Metformina	Metformin

Palavras-chave GNwes (Português)	Palavras-chave The Guardian (Inglês)
Taxa de câmbio	Exchange rate
Dólar	Dollar
IFA	IFA
Reajuste CMED	Drug price adjustment
CONITEC	CONITEC
MACE	Major Adverse Cardiac Events

Fonte: Autoria própria (2026)

Essas palavras foram utilizadas com intuito de delimitar o mercado de diabetes, para aumentar a acurácia do modelo e criar um nicho específico para o escopo da analise prescritiva. Essas foram as palavras identificadas que detém maior influência sobre o mercado de diabetes, com objetivo de encontrar notícias com maior impacto no faturamento dos laboratórios nas venda desses medicamentos.

4.2. Anotação Manual e Análise de Concordância

Os 1.415 artigos foram classificados independentemente por três avaliadores (Anotador 1, Anotador 2, Anotador 3) em três níveis de impacto: alto, médio e baixo entre o período de 2023 e 2026. A Tabela 2 apresenta a distribuição das classificações por avaliador.

Tabela 2: Distribuição das classificações por avaliador

Classe	Anotador 1 (n)	Anotador 1 (%)	Anotador 2 (n)	Anotador 2 (%)	Anotador 3 (n)	Anotador 3 (%)
ALTO	208	14,70%	451	31,87%	236	16,68%
MÉDIO	720	50,88%	603	42,61%	499	35,27%
BAIXO	487	34,42%	361	25,51%	680	48,06%

Fonte: Autoria própria (2026)

A análise da distribuição revela padrões distintos entre os avaliadores: Anotador 1 tendeu a classificar majoritariamente como médio (50,88%), enquanto Anotador 2 atribuiu proporcionalmente mais classificações alto (31,87%) e Anotador 3 classificou mais itens como baixo (48,06%). Essa heterogeneidade de critérios entre avaliadores é consistente com o baixo índice de concordância obtido.

A estatística Kappa de Fleiss, calculada sobre as classificações dos três avaliadores, resultou em $\kappa = 0{,}1858$, interpretado como concordância fraca segundo os critérios de Landis e Koch (1977). O índice de concordância perfeita é os três avaliadores convergindo para a mesma classe em que é de 27,42% (388 itens de 1.415), enquanto 72,58% dos itens (1.027) apresentaram algum nível de discordância. A Tabela 3 apresenta as taxas de concordância por par de avaliadores.

Tabela 3: Concordância por par de avaliadores

Par de Avaliadores	Acordos	Total de Itens	Concordância (%)
Anotador 1 vs Anotador 2	560	1.415	39,58%
Anotador 1 vs Anotador 3	729	1.415	51,52%
Anotador 2 vs Anotador 3	738	1.415	52,16%

Fonte: Autoria própria (2026)

Os índices de concordância por par variaram entre 39,58% (Anotador 1 vs Anotador 2) e 52,16% (Anotador 2 vs Anotador 3), confirmando a dificuldade de alinhamento interpretativo entre os avaliadores. A análise por categoria (Tabela 3) indica que a classe Alto apresentou o menor índice de concordância perfeita (3,32%), enquanto Médio e Baixo obtiveram taxas ligeiramente superiores, porém ainda baixas (13,22% e 10,88%, respectivamente). A Tabela 4 mostra a concordância por categoria de impacto

Tabela 4: Concordância por categoria de impacto

Categoria	Total de Anotações	Concordância Perfeita (n)	Concordância Perfeita (%)	Concordância Parcial (≥2/3)
ALTO	895	47	3,32%	247 (17,46%)
BAIXO	1.528	154	10,88%	493 (34,84%)
MÉDIO	1.822	187	13,22%	511 (36,11%)

Fonte: Autoria própria (2026)

A análise dos padrões de discordância total (casos em que nenhum par de avaliadores concordou) revelou que o padrão mais frequente foi "BAIXO | BAIXO | MÉDIO", correspondendo a 25,90% dos 1.027 itens discordantes (266 casos). A Tabela 5 apresenta os sete padrões de discordância identificados.

Tabela 5: Padrões de discordância total entre avaliadores

Padrão (Anotador 1 | Anotador 2 | Anotador 3)	Frequência	Percentual (%)
BAIXO | BAIXO | MÉDIO	266	25,90%
BAIXO | MÉDIO | MÉDIO	207	20,16%
ALTO | ALTO | MÉDIO	183	17,82%
ALTO | BAIXO | MÉDIO	164	15,97%
ALTO | MÉDIO | MÉDIO	117	11,39%
ALTO | BAIXO | BAIXO	73	7,11%
ALTO | ALTO | BAIXO	17	1,66%

Fonte: Autoria própria (2026)

Diante do baixo índice de concordância e da elevada proporção de discordâncias, foi adotado o Agente de Desempate desenvolvido via *API* da *OpenAI*, responsável por auxiliar na resolução dos casos de discordância total. Essa abordagem visa aumentar a consistência das anotações e melhorar a qualidade da base para as etapas subsequentes de classificação automática.

5. Cronograma

No desenvolvimento de sistemas, o cronograma é o plano temporal que organiza atividades, dependências e marcos para orientar a entrega do produto ao longo do ciclo do projeto. Sua importância está em coordenar o trabalho e alinhar expectativas, pois a gestão moderna trata agenda como um domínio essencial de desempenho para entregar valor com previsibilidade. Ao servir de referência para acompanhamento e ajustes contínuos, o cronograma apoia monitoramento e controle do projeto, permitindo adaptar o planejamento conforme mudanças e restrições. (PROJECT MANAGEMENT INSTITUTE, 2025)

Tabela 6: Cronograma de atividades previstas para o desenvolvimento do sistema

Atividades	Mar	Abr	Mai	Jun	Jul	Ago	Set
Coleta e tratamento de dados (ETL): *APIs The Guardian*, *GNews* e dados sintéticos de vendas	X	X					
Modelagem da arquitetura multiagente e definição dos fluxos de orquestração	X	X					
Anotação manual do corpus (1.415 artigos) e cálculo do *Kappa de Fleiss*	X	X					
Incorporação do Agente de Desempate via *API OpenAI*			X	X			
Desenvolvimento do Agente 1 (Classificador de notícias) com *mBERT*				X	X		
Desenvolvimento do Agente 2 (Validador e Ajuste) com regras de negócio				X	X		
Desenvolvimento dos Agentes 3 (Comparador de Vendas) via *XGBoost*							
Desenvolvimento dos Agentes 4 e 5 (Identificador e Gerador) com GPT-4 e *chain-of-thought*					X	X	
Integração do *pipeline* ETL e testes de ponta a ponta					X		
Validação com dados históricos sintéticos e avaliação de métricas					X	X	
Desenvolvimento do painel de insights, gráficos de desempenho e confiabilidade do modelo					X	X	X

Fonte: Autoria própria (2026)

O cronograma apresentado, sendo referente de março a setembro, foi estruturado como *roadmap* macro para um projeto ágil, no qual o planejamento de alto nível orienta marcos e

dependências, enquanto a execução ocorre em ciclos curtos, chamados de *Sprints*, com inspeção e adaptação contínuas do trabalho e do *backlog* (SCHWABER; SUTHERLAND, 2020; ISO, 2020). Entre março e abril, as atividades concentram-se na fase de iniciação e preparação, incluindo *ETL* e padronização de dados das *APIs GNews, The Guardian* e dados farmacêuticos, definição da arquitetura multiagente e anotação manual do *corpus*; esse desenho reduz incertezas técnicas e aumenta a viabilidade das entregas incrementais subsequentes (ISO, 2020; ARTSTEIN; POESIO, 2008). A confiabilidade da rotulagem é tratada como requisito metodológico por meio da mensuração de concordância entre avaliadores (Kappa), recomendada para avaliar consistência em categorias e apoiar a validade dos resultados experimentais (FLEISS, 1971; LANDIS; KOCH, 1977).

De maio a julho, o desenvolvimento é organizado como fase de construção incremental, priorizando a incorporação de um agente de "desempate" via *API OpenAI* e a implementação de agentes especializados (classificação de notícias e validação por regras), com entregas verificáveis a cada iteração para suportar revisão com orientador e ajustes de escopo (SCHWABER; SUTHERLAND, 2020; OPENAI, 2023). Do ponto de vista técnico, o classificador será baseado em transformadores pré-treinados, como *mBERT* e o comparador de vendas pode empregar modelos de *XGBoost*, pois tais abordagens são consolidadas na literatura como referências de desempenho e escalabilidade em *NLP* e tabular, respectivamente (DEVLIN et al., 2019; CHEN et al., 2026),

Por fim, entre julho e setembro, o plano enfatiza integração, testes pontas a ponta e validação por métricas, culminando na disponibilização de um painel de *insights* e indicadores de desempenho e confiabilidade, o que alinha a entrega técnica à geração de valor e à transparência operacional exigida em projetos ágeis (ISO, 2020; SCHWABER; SUTHERLAND, 2020). Nesse recorte, *frameworks* e bibliotecas de orquestração podem apoiar a composição de componentes baseados em LLMs e agentes, favorecendo modularidade e evolução incremental do sistema (PENG et al., 2023).

6. Conclusão

O estudo propôs e validou parcialmente uma arquitetura multiagente baseada em LLMs para transformar dados comerciais e notícias em recomendações táticas prescritivas no nicho de medicamentos para diabetes. Os resultados parciais indicam viabilidade técnica, com *pipelines* ETL estruturados para o período de 2023 a 2026 e agentes iniciais operacionais em ambiente de testes. O processo de anotação do *corpus* evidenciou alta subjetividade, refletida em um κ baixo, o que reforça a necessidade de governança da rotulagem e de mecanismos de desempate para elevar a consistência dos rótulos. Como contribuição acadêmica, o trabalho entrega um modelo arquitetural replicável e um fluxo metodológico que integra BI, NLP e orquestração de agentes, oferecendo base para novas pesquisas e evoluções do sistema. Para a sociedade e o setor, a proposta aponta um caminho para reduzir o tempo entre "sinal e ação", apoiando decisões comerciais mais rápidas, rastreáveis e consistentes. Como trabalhos futuros, destacam-se o refinamento do protocolo de anotação, a integração completa dos agentes, a ampliação da validação e a evolução do painel para uso em cenários cada vez mais próximos do contexto real.

6. Referências bibliográficas

ANVISA. ***Anuário estatístico do mercado farmacêutico***. Brasília: Agência Nacional de Vigilância Sanitária, 2025. Disponível em: <https://www.gov.br/anvisa/pt-br/assuntos/noticias-anvisa/2025/cmed-divulga-o-anuario-estatistico-do-mercado-farmaceutico>. Acesso em: 10 março 2026.

ARTSTEIN, Ron**; POESIO,** Massimo**.** ***Inter-coder agreement for computational linguistics.*** *Computational Linguistics*, v. 34, n. 4, p. 555–596, 2008. Disponível em: https://doi.org/10.1162/coli.07-034-R2. Acesso em: 10 março 2026.

BROWN, Tom B.**; MANN,** Benjamin**; RYDER,** Nick**; SUBBIAH,** Melanie**; KAPLAN,** Jared**; DHARIWAL,** Prafulla**; NEELAKANTAN,** Arvind**; SHYAM,** Pranav**; SASTRY,** Girish**; ASKELL,** Amanda**; AGARWAL,** Sandhini**; HERBERT-VOSS,** Ariel**; KRUEGER,** Gretchen**; HENIGHAN,** Tom**; CHILD,** Rewon**; RAMESH,** Aditya**; ZIEGLER,** Daniel M.; **WU,** Jeffrey**; WINTER,** Clemens**; HESSE,** Christopher**; CHEN,** Mark**; SIGLER,** Eric**; LITWIN,** Mateusz**; GRAY,** Scott**; CHESS,** Benjamin**; CLARK,** Jack**; BERNER,** Christopher**; MCCANDLISH,** Sam**; RADFORD,** Alec**; SUTSKEVER,** Ilya**; AMODEI,** Dario**.** ***Language models are few-shot learners.*** *arXiv*, 2020. Disponível em: <https://arxiv.org/abs/2005.14165>. Acesso em: 10 março 2026.

CHEN, Tianqi**; HE,** Tong**; BENESTY,** Michael**; KHOTILOVICH,** Vadim**; TANG,** Yuan**; CHO,** Hyunsu**; CHEN,** Kailong**; MITCHELL,** Rory**; CANO,** Ignacio**; ZHOU,** Tianyi**; LI,** Mu**; XIE,** Junyuan**; LIN,** Min**; GENG,** Yifeng**; LI,** Yutian**; YUAN,** Jiaming**; CORTES,** David**.** ***xgboost: Extreme Gradient Boosting*****.** R package version 3.3.0.0, 2026. Disponível em: <https://github.com/dmlc/xgboost>. Acesso em: 10 março 2026.

CRESWELL, John W., **CRESWELL**, J. David. ***Projeto de pesquisa***: métodos qualitativo, quantitativo e misto. Tradução de Magda Lopes. 5. ed. Porto Alegre: Artmed, 2021.

DEL ROSARIO, Ron F.; **KRAWIECKA**, Klaudia; **SCHROEDER DE WITT**, Christian. **Architecting resilient LLM agents***: a guide to secure plan-then-execute implementations.* arXiv, 2025. Disponível em: <https://arxiv.org/pdf/2509.08646>. Acesso em: 10 março 2026.

DEVLIN, Jacob**; CHANG,** Ming-Wei**; LEE,** Kenton**; TOUTANOVA,** Kristina**.** ***BERT*****:** *pre-training of deep bidirectional transformers for language understanding.* In: NORTH AMERICAN CHAPTER OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS: HUMAN LANGUAGE TECHNOLOGIES (NAACL-HLT), 2019, Minneapolis. *Proceedings…* Minneapolis: Association for Computational Linguistics, 2019. p. 4171–4186. Disponível em: https://doi.org/10.18653/v1/N19-1423. Acesso em: 10 março 2026.

FLEISS, Joseph L**.** ***Measuring nominal scale agreement among many raters.*** *Psychological Bulletin*, v. 76, n. 5, p. 378–382, 1971. Disponível em: https://doi.org/10.1037/h0031619. Acesso em: 10 março 2026.

FOURNEY, Adam**; BANSAL,** Gagan**; MOZANNAR,** Hussein**; TAN,** Cheng**; SALINAS,** Eduardo**; ZHU,** Erkang (Eric)**; NIEDTNER,** Friederike**; PROEBSTING,** Grace**; BASSMAN,** Griffin**; GERRITS,** Jack**; ALBER,** Jacob**; CHANG,** Peter**; LOYND,** Ricky**; WEST,** Robert**; DIBIA,** Victor**; AWADALLAH,** Ahmed**; KAMAR,** Ece**; HOSN,** Rafah**; AMERSHI,** Saleema**.** ***Magentic-One:*** *a generalist multi-agent system for solving complex tasks. arXiv*, 2024. Disponível em: <https://doi.org/10.48550/arXiv.2411.04468 >. Acesso em: 10 março 2026.

GARTNER. *Prescriptive analytics in commercial pharma: market guide*. Gartner Research Report, 2023. Disponível em: <https://www.gartner.com/>. Acesso em: 10 março 2026.

GUO, Taicheng**; CHEN,** Xiuying**; WANG,** Yaqi**; CHANG,** Ruidi**; PEI,** Shichao**; CHAWLA,** Nitesh V.; **WIEST,** Olaf**; ZHANG,** Xiangliang**.** ***Large language model based multi-agents:*** *a survey of progress and challenges.* In: INTERNATIONAL JOINT CONFERENCE ON ARTIFICIAL INTELLIGENCE (IJCAI), 33., 2024. *Proceedings…* p. 8048–8057**.** Disponível em: <https://doi.org/10.24963/ijcai.2024/890 > Acesso em: 10 março 2026

IBM. *The AI Ladder:* ***Accelerating AI adoption with prescriptive analytics***. IBM White Paper, 2022. Disponível em: < https://www.ibm.com/analytics/prescriptive-analytics >. Acesso em: 10 março 2026.

LANDIS, J. Richard; **KOCH**, Gary G. ***The measurement of observer agreement for categorical data***. *Biometrics,* v. 33, n. 1, p. 159–174, 1977.

LI, Xinyi; **WANG**, Sai; **ZENG**, Siqi; **WU**, Yu; **YANG**, Yi. **A survey on LLM-based multi-agent systems: workflow, infrastructure, and challenges**. *Vicinagearth*, v. 1, n. 1, art. 9, 2024. Disponível em: <https://doi.org/10.1007/s44336-024-00009-2 >. Acesso em: 10 março 2026.

MICROSOFT. **Vector search in Azure AI Search**. Microsoft Learn, 2026. Disponível em: <https://learn.microsoft.com/en-us/azure/search/vector-search-overview>. Acesso em: 10 março 2026.

OPENAI. ***GPT-4 Technical Report***. OpenAI, 2023. Disponível em: <https://arxiv.org/abs/2303.08774>. Acesso em 10 março 2026.

PENG, Bowen**; LI,** Chunyuan**; HE,** Pengcheng**; GALLEY,** Michel**; GAO,** Jianfeng**.** ***Instruction tuning with GPT-4. arXiv preprint,***[S.l.], 2023. Disponível em: https://arxiv.org/abs/2304.03277. Acesso em: 10 março 2026.

PROJECT MANAGEMENT INSTITUTE. ***The Standard for Project Management*** (PMBOK® Guide – Eighth Edition). Newtown Square, PA: PMI, 2025.

SCHWABER, Ken; **SUTHERLAND**, Jeff. **The Scrum guide***: the definitive guide to Scrum*. 2020. Disponível em: <https://scrumguides.org/docs/scrumguide/v2020/2020-Scrum-Guide-US.pdf>. Acesso em: 10 março 2026.

SILVA, Rodrigo F. **Agentes Inteligentes e Sistemas Especialistas:** a nova fronteira da autonomia tecnológica. 2. ed. São Paulo: TechPress, 2024.

SINGHAL, Karan**; AZIZI,** Shekoofeh**; TU,** Tao**; PANG,** S. Sara**; JALALSYED,** Zel**; BODAS,** Kavita**; DYER,** Eric**; CHENG,** Bin**; LAU,** Curtis**; AKANE,** Jackline**; AGOSTINELLI,** Matthew**; HAYDARI,** S. S.**; KARTIKESWARAN,** S.**; KHADAN,** Azade**; LUI,** Amy**; LIU,** Chia-Chieh**; MAHARECHAL,** Maarten**; XIA,** Fei**; CHI,** Ed**; LE,** Quoc**; ZHOU,** Denny**; NATARAJAN,** Vivek**.** ***Large language models encode clinical knowledge.*** Nature, v. 620, p. 172-180, 2023**.** Disponível em: https://www.nature.com/articles/s41586-023-06291-2. Acesso em: 10 março 2026.

WEI, Jason**; WANG,** Xuezhi**; SCHUURMANS,** Dale**; MAERECHAL,** Maarten**; XIA,** Fei**; CHI,** Ed**; LE,** Quoc**; ZHOU,** Denny**.** ***Chain-of-thought prompting elicits reasoning in large language models.*** In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NEURIPS), 35., 2022, New Orleans. Anais [...]. Red Hook, NY: Curran Associates, Inc., 2022. Disponível em: https://doi.org/10.48550/arXiv.2201.11903. Acesso em: 10 março 2026.

WISSUCHEK, Christopher**; ZSCHECH,** Patrick**.** ***Prescriptive analytics systems revised*****:** *a systematic literature review from an information systems perspective. Information Systems and E-Business Management*, v. 23, n. 2, p. 279–353, 2025. DOI: 10.1007/s10257-024-00688-w. Disponível em: <https://link.springer.com/content/pdf/10.1007/s10257-024-00688-w.pdf>. Acesso em: 10 março 2026.

WU, Qingyun**; BANSAL,** Gagan**; ZHANG,** Jieyu**; WU,** Yiran**; LI,** Beibin**; ZHU,** Erkang**; JIANG,** Li**; ZHANG,** Xiaoyun**; ZHANG,** Shaokun**; LIU,** Jiale**; AWADALLAH,** Ahmed Hassan**; WHITE,** Ryen W.**; BURGER,** Doug**; WANG,** Chi. ***AutoGen:*** *enabling next-gen LLM applications via multi-agent conversation. arXiv*, 2023. Disponível em: <https://doi.org/10.48550/arXiv.2308.08155>. Acesso em: 10 março 2026.